

Embarque de Rede Neural Recorrente Fenomenologicamente Informada para o Controle da Pressão de um Sistema de *Gas Lift*

Silas Henrique Alves Araújo, Nicole Dias de Souza,
Leonardo Silva de Souza, Raony Maia Fontes,
Márcio André Fernandes Martins

8 de outubro de 2025



COBEQ
25º Congresso Brasileiro
de Engenharia Química



ENBEQ
20º Encontro Brasileiro sobre
Ensino de Engenharia Química

Realização



Organização

UFMG



Patrocínio

CONFEDERAÇÃO CREA



Apoio





Motivação do Trabalho

Objetivo Principal

Construir uma **PINN**(Physics Informed Neural Network) que modele o comportamento dinâmico de um sistema de compressão de gás natural.

Especificações

- Basear-se em equações físicas para maior precisão do modelo criado.
- Comparar resultados com o integrador da biblioteca opensource casADi (IDAS).



Contexto Histórico do Tema na Indústria do Petróleo

- **Importância do Transporte de Gás Natural**

- Movimento do gás até consumidores finais (áreas urbanas, indústrias e usinas).
- Processo crucial e com alto custo operacional.

- **Desafios nos Modelos Tradicionais**

- Métodos numéricos possuem alto tempo computacional (Marfatia e Li 2022).
- Modelos aproximados sacrificam precisão para ganhar eficiência computacional.

- **Avanço com Redes Neurais**

- Década de 90: Redes neurais começam a ganhar relevância no setor de petróleo e gás (Mohaghegh et al. 1996).
- Melhor equilíbrio entre eficiência e precisão nos resultados.

- **Physics-Informed Neural Networks (PINNs)**

- Introduzidas em 2017 (Raissi, Perdikaris e Karniadakis 2017).
- Integram dados experimentais e restrições físicas.
- Maior precisão e menor tempo computacional.



Sistema de Compressão




Figura 1: Sistema de Compressão retirado de Meira et al. (2021)



Sistema de Compressão e Gás Natural

Tabela de dados do sistema

Variável	Valor	Unidade
A_1	$2,6 \times 10^{-3}$	m^2
v_P	2,0	m^3
L_C	2,0	m
k_v	0,38	$\text{kg}/(\text{s} \cdot \text{kPa})$
P_1	4,5	MPa
T_1	300	K
$P_{\text{saída}}$	5,0	MPa

O gás natural utilizado é ****rico em metano****, com composição baseada em Chaczykowski (2009):

- CH_4 : 98,34% C_2H_6 : 0,61%
- C_3H_8 : 0,15% iC_4H_{10} : 0,03%
- nC_4H_{10} : 0,03% CO_2 : 0,80%
- Traços de: iC_5H_{12} , nC_5H_{12} , N_2

A equação de estado de Soave (1972) foi utilizada para modelar o comportamento termodinâmico do gás:

$$P = \frac{RT}{V - b} - \frac{a(T)}{V(V + b)}$$

com:

- $a(T)$: fator de correção das forças intermoleculares
- b : correção do volume molecular



Equações Diferenciais do Sistema por Meira et al. (2021)

As equações diferenciais são dadas pelas seguintes expressões:

$$\frac{d\dot{m}}{dt} = \frac{A_1}{L_c} (P_2 - P_P) \quad (1)$$

$$\frac{dV_P}{dt} = -\frac{V_P^2}{v_{PM}} \left(\dot{m} - \alpha k_v \sqrt{P_P - P_{\text{out}}} \right) \quad (2)$$

$$\frac{dT_P}{dt} = \frac{V_P \dot{m}}{v_P M} \left(\frac{h_c - h_p}{C_V} \right) + \frac{R_a T_P}{C_V} \left[T_P \left(\frac{\partial Z_P}{\partial T} \right)_{V_P} + Z_P \right] \frac{V_P}{v_P M} \left(\dot{m} - \alpha k_v \sqrt{P_P - P_{\text{out}}} \right) \quad (3)$$

- \dot{m} : vazão mássica;
- V_P , T_P , Z_P : volume molar, temperatura e fator de compressibilidade do gás no plenum;
- R_a : constante dos gases ideais;
- M : massa molar da mistura;



Variáveis Algébricas estimadas pelo Modelo Meira et al. (2021)

Além das equações diferenciais, o modelo estima 11 variáveis através das equações algébricas, correspondentes ao cálculo do mapa do compressor, da saída das condições do compressor e da equação de estado $P(T,V)$

- P_2 : Pressão na saída do compressor
- T_2 : Temperatura na saída do compressor
- V_2 : Volume específico na saída do compressor
- T_{2s} : Temperatura em um estado intermediário hipotético após a compressão isentrópica
- V_{2s} : Volume específico em um estado intermediário hipotético após a compressão isentrópica
- P_P : Pressão no Plenum
- V_1 : Volume específico na sucção
- V_{imp} : Volume específico no impelidor do compressor
- T_{imp} : Temperatura no impelidor do compressor
- V_{dif} : Volume específico no difusor do compressor
- T_{dif} : Temperatura no difusor do compressor



Estrutura da Rede Neural Proposta

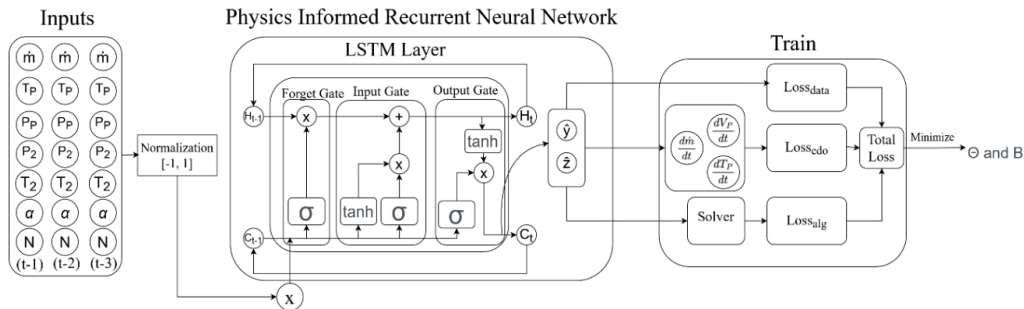


Figura 2: Diagrama da arquitetura da PINN.



Função de Loss

A equação geral da função de perda é:

$$\text{Loss} = \frac{1}{N} \sum_{i=1}^N (\hat{y}_i^* - y_i^*)^2 + \frac{1}{N} \sum_{i=1}^N \left(\frac{d\hat{y}_{i,\text{num}}}{dt} - \frac{d\hat{y}_{i,\text{an}}}{dt} \right)^2 + \frac{1}{N} \sum_{i=1}^N (\hat{z}_i - z_i)^2$$

Onde:

- \hat{y} : variáveis previstas pelas equações diferenciais (rede neural);
- \hat{y}^* : variáveis previstas mensuráveis (saída da rede);
- \hat{z} : variáveis algébricas previstas pela rede;
- z : variáveis algébricas calculadas pelo solver externo.



Escolha dos Hiperparâmetros da rede

- Número de camadas(LSTM): 1
- Taxa de aprendizado inicial (Learning Rate): $1 \cdot 10^{-4}$
- Tamanho da amostra por iteração(Mini batch): 64
- Número de neurônios na camada LSTM: 128
- Número de épocas durante o treinamento: 200
- Otimizador: Adam



Considerações finais

- Usando o *onnxruntime*, a PIRNN foi mais de três vezes mais rápida que os métodos numéricos tradicionais no mesmo computador.
- Mesmo com ruído ou ausência de medições, a PIRNN manteve previsões de boa qualidade, demonstrando sua robustez.
- O controlador PI manteve o controle da planta recebendo apenas os valores previstos pela PIRNN, garantindo operação contínua mesmo sem medições diretas.

Agradecimentos

Agradeço à Agência Nacional do Petróleo, Gás Natural e Biocombustíveis (ANP), no âmbito do PRH 35.1, pelo suporte financeiro e apoio ao desenvolvimento deste trabalho.



COBEQ
25º Congresso Brasileiro
de Engenharia Química



ENBEQ
20º Encontro Brasileiro sobre
Ensino de Engenharia Química



Realização



Organização

UFMG



Patrocínio

CONFEA CREA






Apoio





Bibliografia I

-  Marfatia, Zaid e Xiang Li (2022). “Data-Driven Natural Gas Compressor Models for Gas Transport Network Optimization”. Em: *Digital Chemical Engineering* 3, p. 100030. ISSN: 2772-5081.
-  Mohaghegh, Shahab et al. (1996). “Petroleum reservoir characterization with the aid of artificial neural networks”. Em: *Journal of Petroleum Science and Engineering* 16.4, pp. 263–274.
-  Raissi, Maziar, Paris Perdikaris e George Em Karniadakis (2017). “Physics Informed Deep Learning (Part I): Data-driven Solutions of Nonlinear Partial Differential Equations”. Em: *arXiv preprint arXiv:1704.03718*.