

Embarque de Rede Neural Recorrente Fenomenologicamente Informada para o Controle da Pressão de um Sistema de *Gas Lift*

Silas Henrique Alves Araújo, Nicole Dias de Souza,
Leonardo Silva de Souza, Raony Maia Fontes,
Márcio André Fernandes Martins

8 de outubro de 2025



COBEQ
25º Congresso Brasileiro
de Engenharia Química



ENBEQ
20º Encontro Brasileiro sobre
Ensino de Engenharia Química

Realização



Organização

UFMG



Patrocínio

CONFEE CREA



Apoio





Contexto e Objetivo do Trabalho

Contexto Histórico na Indústria do Petróleo:

- **Importância do Transporte de Gás Natural:** movimentar o gás até consumidores finais (indústrias, usinas, centros urbanos) é um processo essencial, porém com alto custo operacional.
- **Limitações dos Modelos Tradicionais:** métodos numéricos apresentam elevado tempo computacional (Marfatia e Li 2022), enquanto modelos aproximados sacrificam precisão.
- **Avanços com Redes Neurais:** desde os anos 90, redes neurais têm sido aplicadas no setor (Mohaghegh et al. 1996), buscando equilíbrio entre precisão e eficiência.
- **Physics-Informed Neural Networks (PINNs):** propostas por Raissi, Perdikaris e Karniadakis 2017, integram dados experimentais às leis físicas, aumentando a precisão e reduzindo o tempo de simulação.

Objetivo Principal

Construir uma **PINN** (Physics Informed Neural Network) que modele o comportamento dinâmico de um sistema de compressão de gás natural.



Sistema de Compressão




Figura 1: Sistema de Compressão retirado de Meira et al. (2021)



Sistema de Compressão e Gás Natural

Tabela de dados do sistema

Variável	Valor	Unidade
A_1	$2,6 \times 10^{-3}$	m^2
v_P	2,0	m^3
L_C	2,0	m
k_v	0,38	$\text{kg}/(\text{s} \cdot \text{kPa})$
P_1	4,5	MPa
T_1	300	K
$P_{\text{saída}}$	5,0	MPa

O gás natural utilizado é rico em metano, com composição baseada em Chaczykowski (2009):

- CH_4 : 98,34% C_2H_6 : 0,61%
- C_3H_8 : 0,15% iC_4H_{10} : 0,03%
- nC_4H_{10} : 0,03% CO_2 : 0,80%
- Traços de: iC_5H_{12} , nC_5H_{12} , N_2

A equação de estado de Soave (1972) foi utilizada para modelar o comportamento termodinâmico do gás:

$$P = \frac{RT}{V - b} - \frac{a(T)}{V(V + b)}$$

com:

- $a(T)$: fator de correção das forças intermoleculares
- b : correção do volume molecular



Equações e Variáveis do Modelo de Meira et al. (2021)

Equações diferenciais que descrevem a dinâmica do sistema:

$$\frac{d\dot{m}}{dt} = \frac{A_1}{L_c} (P_2 - P_P) \quad (1)$$

$$\frac{dV_P}{dt} = -\frac{V_P^2}{v_{PM}} \left(\dot{m} - \alpha k_v \sqrt{P_P - P_{out}} \right) \quad (2)$$

$$\begin{aligned} \frac{dT_P}{dt} = & \frac{V_P \dot{m}}{v_P M} \left(\frac{h_c - h_p}{C_V} \right) + \\ & + \frac{R_a T_P}{C_V} \left[T_P \left(\frac{\partial Z_P}{\partial T} \right)_{V_P} + Z_P \right] \frac{V_P}{v_P M} \left(\dot{m} - \alpha k_v \sqrt{P_P - P_{out}} \right) \end{aligned} \quad (3)$$

Principais variáveis algébricas estimadas:

- P_2, T_2, V_2 : saída do compressor
- T_{2s}, V_{2s} : pós-compressão isentrópica
- V_1 : sucção do compressor
- V_{imp}, T_{imp} : impelidor
- V_{dif}, T_{dif} : difusor
- P_P : pressão no plenum

Símbolos:

- \dot{m} : vazão mássica; V_P, T_P, Z_P : volume molar, temperatura e fator de compressibilidade no plenum; R_a : constante dos gases; M : massa molar; h_c, h_p : entalpias; C_V : calor específico a volume constante.



Estrutura da Rede Neural Proposta




Figura 2: Diagrama da arquitetura da PINN.



Função de Loss e Hiperparâmetros da Rede

A equação geral da função de perda utilizada foi:

$$\text{Loss} = \frac{1}{N} \sum_{i=1}^N (\hat{y}_i^* - y_i^*)^2 + \frac{1}{N} \sum_{i=1}^N \left(\frac{d\hat{y}_{i,\text{num}}}{dt} - \frac{d\hat{y}_{i,\text{an}}}{dt} \right)^2 + \frac{1}{N} \sum_{i=1}^N (\hat{z}_i - z_i)^2$$

Onde:

- \hat{y}^* : variáveis previstas mensuráveis (saída da rede);
- y^* : variáveis reais mensuráveis (target);
- \hat{z} : variáveis algébricas previstas pela rede;
- z : variáveis algébricas calculadas pelo solver extemp.

Hiperparâmetros do Modelo

Parâmetro	Valor
Nº de camadas (LSTM)	1
Learning Rate inicial	$1 \cdot 10^{-4}$
Tamanho do mini batch	64
Neurônios por camada	128
Nº de épocas	200
Otimizador	Adam



Considerações finais

- Usando o *onnxruntime*, a PIRNN foi mais de três vezes mais rápida que os métodos numéricos tradicionais no mesmo computador.
- Mesmo com ruído ou ausência de medições, a PIRNN manteve previsões de boa qualidade, demonstrando sua robustez.
- O controlador PI manteve o controle da planta recebendo apenas os valores previstos pela PIRNN, garantindo operação contínua mesmo sem medições diretas.

Agradecimentos

Agradeço à Agência Nacional do Petróleo, Gás Natural e Biocombustíveis (ANP), no âmbito do PRH 35.1, pelo suporte financeiro e apoio ao desenvolvimento deste trabalho.



Realização



Organização



Patrocínio






Apoio





Bibliografia I

-  Marfatia, Zaid e Xiang Li (2022). “Data-Driven Natural Gas Compressor Models for Gas Transport Network Optimization”. Em: *Digital Chemical Engineering* 3, p. 100030. ISSN: 2772-5081.
-  Mohaghegh, Shahab et al. (1996). “Petroleum reservoir characterization with the aid of artificial neural networks”. Em: *Journal of Petroleum Science and Engineering* 16.4, pp. 263–274.
-  Raissi, Maziar, Paris Perdikaris e George Em Karniadakis (2017). “Physics Informed Deep Learning (Part I): Data-driven Solutions of Nonlinear Partial Differential Equations”. Em: *arXiv preprint arXiv:1704.03718*.